



Primer proyecto: Técnicas de aprendizaje de máquina

Diego Caballero Sarmiento

Liseth Lozano

Aura Atuesta

Pontificia Universidad Javeriana

Docente: Julio Omar Palacio Niño

Bogotá, Colombia

2024-3

Abstract: Este proyecto aborda la clasificación en aprendizaje automático utilizando el conjunto de datos de batallas de Clash Royale. Se analizará la dimensionalidad de la información y se implementarán tres modelos: regresión logística, una red neuronal feed-forward y un enfoque híbrido que combina técnicas de preprocesamiento con algoritmos de clasificación. El proyecto busca comparar el rendimiento de estos métodos en la predicción de resultados de partidas. Se evaluarán las métricas vistas en clase para determinar la eficacia de cada modelo. El objetivo es proporcionar diferentes perspectivas sobre la aplicación de diversas estrategias de machine learning en un contexto específico, explorando cómo diferentes técnicas pueden mejorar la precisión para perfeccionar la clasificación de los combates dentro del juego.

Introducción

El aprendizaje automático (machine learning) ha revolucionado numerosos campos, y su aplicación en el análisis de juegos competitivos ofrece interesantes oportunidades de investigación. Este proyecto se centra en el popular juego móvil Clash Royale, explorando cómo las técnicas de machine learning pueden utilizarse para predecir los resultados de las batallas.

Clash Royale, un juego de estrategia en tiempo real, presenta un complejo ecosistema de cartas, tropas y mecánicas que influyen en el desenlace de cada enfrentamiento. El desafío principal que se aborda es:

¿Cómo podemos utilizar diferentes modelos de machine learning para predecir con precisión los resultados de las batallas en Clash Royale?

Para responder a esta pregunta, se propone analizar un conjunto de datos de batallas de alto nivel, implementando y comparando tres enfoques distintos:

1. Un modelo de regresión logística
2. Una red neuronal feed-forward
3. Un enfoque híbrido que combina técnicas de preprocesamiento con algoritmos de clasificación

A través de este análisis, se busca no solo mejorar la precisión en la predicción de resultados, sino también profundizar en el funcionamiento detallado de los distintos métodos de aprendizaje automático. Esto incluye entender sus características, ventajas, limitaciones y la forma en que se comportan en distintos escenarios. Estos conocimientos son cruciales para poder seleccionar adecuadamente los modelos más apropiados según el tipo de problema y los datos disponibles.

Asimismo, este proyecto brinda la oportunidad de explorar de manera más exhaustiva la eficacia de diversas técnicas de machine learning en un entorno de datos del mundo real, lo cual es esencial para desarrollar soluciones que sean aplicables a problemas prácticos. Al trabajar en un contexto con datos complejos, se espera adquirir una comprensión más profunda y matizada sobre cómo ajustar y aplicar estos enfoques de manera efectiva. Esto, a su vez, permitirá no solo mejorar la toma de decisiones, sino también aportar valor a través de la aplicación de métodos avanzados en situaciones del mundo real que requieren soluciones adaptables e innovadoras.

Aproximación al Problema

Para abordar la pregunta de cómo predecir con precisión los resultados de las batallas en Clash Royale, se utilizaron dos conjuntos de datos: cardlist, que contiene la lista de cartas junto con sus respectivos IDs, y dataord, que incluye la información detallada de las partidas.

Inicialmente se realizó un análisis exploratorio con el objetivo de conocer las características de los datasets presentados, en el cual se encontró:

- Cardlist: Las dimensiones del conjunto de datos cardlist son 106 filas y 3 columnas.
- Dataord: Las dimensiones del conjunto de datos cardlist son 718886 filas y 20 columnas.

A continuación, se describen en detalle cada una de las aproximaciones:

1. *Modelo de regresión logística:*

a) Preprocesamiento de Datos:

- **Normalización:** Los datos se normalizaron utilizando StandardScaler para ajustar las características a una distribución estándar con media 0 y desviación estándar 1. Esto asegura que todas las características contribuyan de manera equitativa al proceso de entrenamiento del modelo.
- **Reducción de dimensionalidad:** Se aplicó PCA (Análisis de Componentes Principales) para reducir el número de características a 34 componentes principales y variabilidad. Esto ayuda a manejar la alta dimensionalidad y potencialmente mejorar el rendimiento del modelo al eliminar ruido y redundancia.

b) Creación del modelo: Se configuró el modelo con el parámetro `class_weight='balanced'`, con el objetivo de compensar el ligero desbalance en las clases del conjunto de datos, ajustando automáticamente los pesos de las clases según su proporción en el conjunto de datos. De tal forma que el modelo aprenda de manera más efectiva sobre estas clases y, en consecuencia, mejore la precisión de las predicciones para todas las clases.

c) Entrenamiento del modelo:

- **Umbral:** El umbral de decisión se ajustó a 0.4 con el objetivo de mejorar la precisión y recall del modelo, especialmente en la clase 0 (minoritaria).

2. Modelo de red neuronal feed-forward:

a) Preprocesamiento de Datos: De igual forma que en la regresión logística, el preprocesamiento de este modelo incluye normalización de los datos a través de StandardScaler y PCA con 34 componentes.

b) Arquitectura:

- **Capa de entrada:** Primera capa oculta con 28 neuronas y función de activación ReLU. Esta capa toma como entrada un vector de características con 34 dimensiones (después de la reducción de dimensionalidad con PCA).
- **Capas ocultas:** Segunda capa oculta con 14 neuronas y función de activación ReLU. Estas capas ayudan a capturar y aprender las interacciones complejas entre las características.
- **Capa de salida:** Capa final con 1 neurona y función de activación sigmoid. La función sigmoid es utilizada para generar una probabilidad entre 0 y 1, que indica la probabilidad de que el Jugador 1 pierda (clasificación binaria).
- **Parámetros totales:** Con el uso de las capas se trabaja con un total de 1.401 parámetros totales y entrenables.

c) Entrenamiento del modelo:

- **Función de pérdida:** Se utilizó binary_crossentropy, que mide la diferencia entre las probabilidades predichas y las etiquetas verdaderas.
- **Optimizador:** Adam fue elegido como optimizador con una tasa de aprendizaje de 0.001. Es útil para la convergencia de los datos y es eficiente en problemas con grandes cantidades de datos y parámetros.

- **Épocas y tamaño del lote:** El modelo fue entrenado durante 25 épocas con un tamaño de lote de 64. Esto controla el número de veces que se actualizan los pesos en cada iteración del entrenamiento.
- **Umbral:** El umbral de decisión se ajustó a 0.56 para mejorar la precisión y recall del modelo. El ajuste del umbral optimiza el rendimiento del modelo para una clase específica.

3. ***Modelo Híbrido de Clasificación con Preprocesamiento***, nuestro enfoque combina técnicas de preprocesamiento con algoritmos de clasificación para mejorar la precisión predictiva. Este modelo híbrido se estructura de la siguiente manera:

a) Preprocesamiento de Datos:

- Aplicación de técnicas de selección de características para identificar los atributos más relevantes en la predicción de resultados de batallas.
- Utilización de métodos de reducción de dimensionalidad, como PCA (Análisis de Componentes Principales), para manejar la alta dimensionalidad de los datos de Clash Royale.

b) Clasificador de Bayes como Paso Intermedio:

- Uso de un clasificador Naive Bayes para generar probabilidades preliminares de victoria/derrota basadas en las características seleccionadas.

c) Ensamblaje de Modelos:

- Implementación de un enfoque de ensamblaje que combina múltiples algoritmos de clasificación, incluyendo árboles de decisión, bosques aleatorios.

d) Validación Cruzada y Ajuste de Hiperparámetros:

- Empleo de validación cruzada para evaluar el rendimiento del modelo y asegurar su generalización.
- Uso de técnicas de optimización de hiperparámetros, como búsqueda en cuadrícula o búsqueda aleatoria, para afinar el rendimiento del modelo ensamblado.

Resultados

Modelo de regresión logística:

- **Matriz de confusión:**

```
Matriz de Confusión:
[[ 262 95172]
 [ 243 119989]]
```

- **Reporte de clasificación:**


```
Reporte de Clasificación:
              precision    recall  f1-score   support

     0       0.52         0.00         0.01       95434
     1       0.56         1.00         0.72      120232

 accuracy              0.56       215666
 macro avg           0.54         0.50         0.36       215666
 weighted avg       0.54         0.56         0.40       215666
```

El modelo de clasificación presenta un desempeño desbalanceado al identificar correctamente casi todos los casos de la clase 1 (recall cercano a 1), sin embargo, su capacidad para identificar correctamente la clase 0 es muy baja (recall cercano a 0). Esto sugiere un sesgo hacia la clase mayoritaria (1) y una dificultad para detectar la clase minoritaria (0).

- **Curva ROC:**



El modelo no tiene capacidad para discriminar entre las dos clases. Es decir, no es mejor que un modelo aleatorio en la tarea de clasificación.

Red neuronal feed-forward:

- **Matriz de confusión:**

[[25045 70389]

[22672 97560]]


El modelo tiene dificultades para predecir correctamente cuándo el Jugador 1 gana (mayor número de falsos negativos) y es más efectivo en predecir cuándo el Jugador 1 pierde (mayor número de verdaderos negativos).

- **Métricas de Clasificación:**

	precision	recall	f1-score	support
0	0.60	0.48	0.54	119471
1	0.49	0.61	0.54	96195
accuracy			0.54	215666
macro avg	0.55	0.55	0.54	215666
weighted avg	0.55	0.54	0.54	215666

El modelo muestra un desbalance en la capacidad de predecir las dos clases. Tiene un mejor desempeño en identificar pérdidas (Clase 1) en comparación con ganancias (Clase 0). También se observa que el modelo tiene un recall relativamente alto para la clase 1, pero una precisión más baja. Esto puede indicar que el modelo tiende a predecir pérdidas con mayor frecuencia, aunque con menos precisión.


- **Curva de precisión:**



Precisión de entrenamiento: Muestra una tendencia general ascendente, lo que indica que el modelo mejora su precisión en los datos de entrenamiento con el tiempo (épocas).

Precisión de validación: Aunque tiene más variaciones, también muestra una tendencia ascendente, lo que sugiere que el modelo está mejorando su precisión en los datos de validación. Las variaciones podrían ser un indicativo de sobreajuste.


- **Curva de error:**



En el error de entrenamiento se observa que comienza alrededor de 0.685 y disminuye a medida que aumentan las épocas. Esto indica que el modelo está aprendiendo bien durante el entrenamiento.

En el error de validación se observa que muestra alteraciones mientras disminuye, terminando alrededor de 0.679. Esto puede indicar que el modelo está experimentando variaciones en su rendimiento en datos no vistos (validación) o sobreajuste.

- **Curva ROC:**



La curva se desvía ligeramente hacia la esquina superior izquierda, lo que indica que el modelo tiene cierta capacidad predictiva, aunque no es muy fuerte y obtiene un AUC igual a 0.57, lo que indica que el modelo tiene una capacidad baja a moderada para distinguir entre las clases.

Modelo Híbrido

El modelo propuesto combina varias técnicas de análisis y preprocesamiento para mejorar la clasificación. Comienza con un muestreo aleatorio del 10% de los datos para manejar eficientemente grandes volúmenes de información debido a que en Colab no podía correr y se buscó una forma de que se pudiera ejecutar en cualquier entorno, sin embargo también se probó sin una muestra y los resultados fueron peores. Luego, se aplican técnicas de preprocesamiento que incluyen la imputación de valores faltantes mediante SimpleImputer y el escalado de características con StandardScaler. A continuación, utiliza SelectFromModel con un clasificador LightGBM para realizar una selección de características, reduciendo la dimensionalidad del conjunto de datos. Finalmente, emplea LightGBM como clasificador principal, aprovechando su eficiencia y alto rendimiento.

En el proceso de desarrollo de este modelo, se experimentó con diversas técnicas de clasificación y preprocesamiento. Inicialmente, se probaron algoritmos como Random Forest, que aunque ofrecía una buena precisión, consumía demasiados recursos computacionales, causando que el PC se sobrecargara en conjuntos de datos más grandes. Se exploró el uso de SVM (Support Vector Machines) con diferentes kernels, pero su rendimiento en términos de precisión fue inferior al esperado. Además, se experimentó con técnicas de ensemble más complejas como XGBoost y Stacking, pero estas requerían un tiempo de procesamiento significativamente mayor sin saber si ofrece mejoras sustanciales en la precisión.


Resultados:

Reporte de Clasificación:

	precision	recall	f1-score	support
0	0.51	0.18	0.26	9513
1	0.57	0.87	0.69	12054
accuracy			0.56	21567
macro avg	0.54	0.52	0.48	21567
weighted avg	0.55	0.56	0.50	21567

Precisión: 0.5634070570779431

Los resultados muestran un rendimiento moderado del modelo, con una precisión general de 0.56, ligeramente superior al azar. Se observa un desequilibrio significativo entre las clases (9513 vs 12054 instancias), lo que se refleja en el mejor desempeño del modelo en la clase mayoritaria (clase 1: precisión 0.57, recall 0.87) en comparación con la clase minoritaria (clase 0: precisión 0.51, recall 0.18). Este sesgo hacia la clase mayoritaria se evidencia también en el F1-score promedio ponderado de 0.50, que indica un rendimiento moderado al considerar el balance entre precisión y recall.



El área bajo la curva (AUC) de 0.56 indica que el modelo tiene una capacidad predictiva modesta, superando ligeramente el nivel de azar (0.5). La curva ROC, representada por la línea naranja, se sitúa por encima de la línea diagonal punteada azul, que representa una predicción aleatoria. Esto sugiere que el modelo muestra cierta capacidad para discriminar entre clases positivas y negativas, aunque hay margen considerable para mejorar su rendimiento y aumentar su precisión en la clasificación.

Conclusiones

El proyecto aborda la forma de predecir los resultados de las batallas en Clash Royale utilizando diferentes modelos de machine learning. Se implementaron tres enfoques distintos: regresión logística, una red neuronal feed-forward y un enfoque híbrido que combina técnicas de preprocesamiento con algoritmos de clasificación.

Los resultados sugieren que la tarea de predicción es compleja y presenta desafíos bastante difíciles. Tanto el modelo de regresión logística como la red neuronal feed-forward mostraron un desempeño desequilibrado, con una tendencia a favorecer una clase sobre la otra. Esto se evidencia en las matrices de confusión y los reportes de clasificación, donde se observa una

alta tasa de aciertos para una clase (generalmente la clase mayoritaria) pero un rendimiento pobre para la otra.

La curva ROC para el modelo de regresión logística indica que no tiene capacidad para discriminar entre las dos clases, comportándose de manera similar a un modelo aleatorio. Esto sugiere que las características seleccionadas o el modelo en sí no son adecuados para capturar la complejidad de los factores que determinan el resultado de las batallas.

Por otro lado, la red neuronal feed-forward mostró algunas mejoras, con una tendencia ascendente en las curvas de precisión tanto para los datos de entrenamiento como de validación. Sin embargo, las variaciones en la curva de error de validación sugieren posibles problemas de sobreajuste, indicando que el modelo podría estar aprendiendo patrones específicos de los datos de entrenamiento que no se generalizan bien a nuevos datos.

Por último el modelo híbrido, en sus métricas de evaluación revela un desequilibrio en el desempeño del modelo entre las diferentes clases. La curva ROC dice que el modelo tiene una capacidad predictiva ligeramente superior a la aleatoria, lo que indica que hay margen considerable para mejorar. Este rendimiento moderado podría atribuirse a la complejidad de predecir los resultados de las batallas en Clash Royale, donde múltiples factores sutiles pueden influir en el desenlace.

Estos resultados destacan la dificultad del problema de predicción en Clash Royale, donde múltiples factores pueden influir en el resultado de una batalla. La dificultad para lograr un rendimiento equilibrado entre las clases sugiere que podría ser necesario un enfoque más complejo, como el modelo híbrido propuesto.

En general, el proyecto ilustra los desafíos comunes en aplicaciones de machine learning en contextos del mundo real, donde la selección de características, el manejo de desbalances de

clase y la optimización de modelos juegan un papel crucial en el rendimiento final. Además, la importancia de un análisis cuidadoso de los resultados y la necesidad de iterar sobre los modelos para mejorar su capacidad predictiva hacen que sea una gran forma de aprendizaje.